第十章 概率与统计

10.3 统计的基本概念

统计学，简单地说，就是从数据中认识世界的一门学问. 在现实生活中，人们常常需要根据有限的资料，推断整体情况，比较不同现象，并作出合理判断. 统计学正是通过对数据进行收集、整理、分析和解释，把零散的信息转化为有用的结论，这套分析方式已经深入到了国家宏观政策的科学制定，社会经济管理、学术研究甚至个人的生活与工作.

我们通常认为数学答案只有对错之分. 但很多时候——至少在统计学中——情况并非如此. 统计研究的基础是数据，对每一个数据而言，都具有不确定性，此后通过各种方式对数据进行归纳推理、分析判断，最终得到的结论也可能是不同的，而且很难说哪一种方法是对的。因此，统计学关系更多的是“好”与“不好”，通常认为，能更客观地反映实际背景的方法要好一些。以新冠病毒总死亡人数为例，这一最终结果实际由以下几种数据合成：与新冠病毒直接相关的死亡病例数（CDC[1]），今年某地的死亡人数与过去几年该地的统计平均值进行比较得出的“超额”死亡人数（EuroMOMO[2]），模型估计的死亡人数（WHO[3]）等。不同的统计方向会给出非常不同的答案，该用哪个，取决于我们想要回答什么问题以及是否有能力实施该方案.[4].

统计学不止是一种方法或技术，它还含有世界观的成分，为我们提供了看待万事千物的一种视角. “用数据说话”已经成为当今时代的一大特征，在信息爆炸的年代，我们将随时随地成为数据的接收者。散布在报纸、杂志、电视、广播、媒体中的数据，良莠并存、真伪同在，即使同一组真实的数据，也有着截然不同的解读方式，如何从纷繁的数据中串联出有用的信息？如何识破统计的骗局……可以说，统计学已经成为了现代人认识世界的一大基本素养.

10.4 统计的基本概念

10.4.1 总体与个体

在统计问题中，把研究对象的全体称为**总体**，总体中的每一个对象称为**个体**. 总体中所含个体的数量称为**总体的容量**. 例如，要考察某大学学生的身高，则该校的全体学生的身高构成一个总体，每个学生的身高则是该总体中的一个个体.

在许多实际问题中，当总体容量很大或检测过程具有一定的破坏性时[5]，很难直接研究总体，这时可以通过从总体中抽取一部分个体进行研究，根据该部分的情况去估计总体的相应情况，抽取出的这部分个体称为**样本**，样本中所含个体的数量称为**样本大小**或**样本容量**.

---

[1] Centers for Disease Control and Prevention，美国疾病控制与预防中心.

[2] European monitoring of excess mortality for public health action，欧洲公共卫生行动超额死亡监测系统.

[3] World Health Organization，世界卫生组织.

[4] 对于死亡登记不完整的国家，WHO 无法直接取得全部实际死亡人数，就会利用模型进行估计.

[5] 例如，在检测血常规时，一般不会将人的所有血液抽出进行检测.

10.4.2　抽样方法

人们在日常生活中经常不自觉地使用抽样方法. 在厨房煮汤时，为考察汤的味道，没必要把汤全喝完，只要把汤搅拌均匀，从中品尝一勺就够了. 这一生活实例为我们进行抽样调查活动并收集数据提供了一些启发：“把汤搅拌均匀”是为了保证抽样的随机性，没有抽样的随机性，样本就不能很好地反映总体的情况；“品尝一勺”则表明选取的样本量不能太少，也不必太大，太少了不足以品出味道，品尝一大碗也没必要.

科学的抽样方法要求样本具有代表性，这指的是，选取的样本能客观地反映总体的情况，没有人为的主观偏向.

在抽样时不放回地逐个抽取若干个体作为样本，如果在每次抽取时，未进入总体中的诸个体被抽到的概率都相等，则称这种抽样方法为**（不放回）简单随机抽样**. 统计研究必须遵循随机抽样原则.

简单随机抽样有何局限性呢？以下述问题为例：假设某高中有学生 3000 人，且男女学生比例大致相同，现在需要通过抽样来估计学生的平均身高，样本容量为 100. 简单随机抽样虽然使得总体中每一个个体都有相等的机会被抽中，但因为抽样的随机性，有可能会出现较为“极端”的样本，即样本中的个体大部分为高个子或矮个子. 能否利用总体中的额外信息对抽样方法进行改进，降低这种情况的出现概率呢？

我们知道，性别是影响身高的一个主要因素，高中男生的身高普遍高于女生的身高，而相同性别的身高差异相对较小. 据此，我们可以把学生分成男生和女生这两个群体，再对两个群体分别进行简单随机抽样，然后汇总作为总体的一个样本。为使样本结构与总体分布相近，人数多的群体应多抽一些，人数少的群体应少抽一些. 按男生、女生在全体学生中所占的比例进行分配是一种比较合理的方式，即

$$\text{男生样本量} = \frac{\text{男生人数}}{\text{全体学生数}} \times \text{总样本量}, \text{女生样本量} = \frac{\text{女生人数}}{\text{全体学生数}} \times \text{总样本量}$$

一般地，当总体由差异明显的几个部分组成时，通常先按一个或多个特征把总体划分成若干个子总体，在每个子总体中独立地进行简单随机抽样，再把从所有子总体中抽取的样本合并作为总样本，这样的抽样方法称为**分层随机抽样**，每一个子总体称为**层**，在分层随机抽样中，如果每层样本量都与层的大小成比例，那么称这种样本量的分配方式为**比例分配**.

分层随机抽样有诸多好处，如果层内个体差异较小，而层与层之间差异较大，那么分层抽样可以显著降低层间差异对抽样误差的影响. 在相同的样本量下，分层抽样得到的总体估计值的方差通常比简单随机抽样更小. 此外，分层抽样允许研究者不仅能推断总体，还能对不同层的子总体进行分析和比较. 在实际操作中，不同层级的群体可能分布在不同的地理位置或由不同的部门进行管理，分层后可以针对不同层采用不同的调查方法或由不同的调查团队实施调查.

10.4.3　统计图表

通过统计得到的原始数据一般都是杂乱无章的，不便于阅读、理解与分析. 人们借助统计图表对获取到的原始数据加以整理，并用简明醒目的方式加以表述，使得这些数据变得一目

了然，清晰易懂，所谓“一图胜千言”.

我们在初中阶段学习了扇形统计图，折线统计图和条形统计图等，高中阶段则新接触了频率分布直方图、频率分布折线图等，此处不做详述.

10.4.4 用样本估计总体

前面谈了收集、整理和描述统计数据的一些基本方法. 通过对统计数据的整理与描述，我们对客观事物的概貌有了一定了解，但这还不够，接下来需要选择适当的统计方法分析数据，并从数据中提取有用信息，进而了解数据背后的规律.

当难以获取总体的全部数据时，我们通常用样本的数字特征来估计总体的数字特征. 描述总体数字特征的指标也称为**参数**，常见的总体参数有总体平均数、众数和中位数以及总体方差等等，通常用希腊字母表示，例如总体平均数常用 μ 表示. 描述样本数字特征的指标也称为**统计量**，它是根据样本计算得到的量，常见的有样本平均数、样本方差等，通常用英文字母表示，例如样本平均数常用 $\overline{x}$ 表示.

平均数，众数以及中位数作为一组数据的代表，可以用来刻画该组数据的集中趋势.

平均数也称为均值，是刻画一组数据集中趋势最主要的指标. 总体均值作为总体的指标，是一个固定的量，而样本均值则依赖于样本的选择，具有随机性，但实践和理论都表明，当样本数量增加时，样本均值 $\overline{x}$ 会向总体均值 μ 接近，于是我们一般用 $\overline{x}$ 估计 μ.

众数是一组数据中出现次数最多的数（如果有多个数满足，那么这些数都是众数）. 中位数指的是将一组观测数据从小到大排列后，处于中间位置的数，可以用来表示总体的“中等”水平. 众数和中位数都不受极端值的影响.

极差，方差，标准差则可以用来刻画该组数据的离散程度.

极差是一组数据中最大值与最小值的差，是描述数据离散程度的最简单的指标，容易受极端值的影响.

方差这一指标的计算方式如下，设总体中有 N 个个体 $x_1, x_2, \cdots, x_N$，总体平均数为 μ，则总体方差为 $\sigma^2 = \dfrac{1}{N}\sum\limits_{i=1}^{N}(x_i-\mu)^2$. 设从总体中随机抽样，获得 n 个观测数据 $x_1, x_2, \cdots, x_n$，设样本平均数为 $\overline{x}$，则样本方差为 $s^2 = \dfrac{1}{n}\sum\limits_{i=1}^{n}(x_i-\overline{x})^2$.[6]

样本方差 s^2 刻画了样本数据相对于样本均值 $\overline{x}$ 集中或离散的程度. 当样本容量较大时，通常用样本方差估计总体方差.

方差的单位是观测数据单位的平方，为标准化量纲，我们引入 **标准差**，标准差是方差的算术平方根，总体标准差记为 σ，样本标准差记为 s.

显然，上述统计量还不足以使我们了解这些数据的分布特点. 鉴于此种需求，我们引入分位数的概念。

一组数据的**第 p 百分位数**（p 是一个 1 到 100 之间的整数值）是这样一个值，它使得这组数据中至少有 $p\%$ 的数据小于或等于这个值，且至少有 $(100-p)\%$ 的数据大于或等于这个

[6]在大学讲授的统计学中，定义样本方差为 $s^2 = \dfrac{1}{n-1}\sum\limits_{i=1}^{n}(x_i-\overline{x})^2$，这样定义的样本方差具有无偏性。

值.

中位数就是第 50 百分位数，在实际应用中，常用的分位数还有**第 25 百分位数**, **第 75 百分位数**. 这两个分位数也被称为**四分位数**，其中第 25 百分位数被称为**第一四分位数**或**下四分位数**，第 75 百分位数被称为**第三四分位数**或**上四分位数**.

计算一组 n 个数据的第 p 百分位数的常用方法如下，先按从小到大的顺序排列原始数据. 计算出 $i = n \times p\%$. 若 i 不是整数, 则取第 p 百分位数为第 $\lceil i \rceil$ 个数据；若 i 是整数, 则取第 p 百分位数为第 i 项与第 $(i+1)$ 项数据的平均数.

第十章 概率与统计

10.3 统计的基本概念

习 题

A 组

1.【湘教版必修一习题 6.6.1】为了解北京市初中学业水平考试中数学成绩的情况，从参加考试的学生中随机抽查了 1000 名学生的数学成绩进行统计分析. 在这个问题中，下列说法正确的是

(A) 总体指的是该市参加学业水平考试的全体学生

(B) 个体指的是 1000 名学生中的每一名学生

(C) 样本容量是指 1000 名学生

(D) 样本是指 1000 名学生的数学学业水平考试成绩

2.【人教 A 版选修二习题 5.3.9】设 $x_1,x_2,\ldots,x_n$ 为样本数据，令 $f(x)=\sum_{i=1}^{n}(x_i-x)^2$，则 $f(x)$ 的最小值点为

(A) 样本众数 (B) 样本中位数 (C) 样本标准差 (D) 样本平均数

3.【2020 全国 III 卷理 3】在一组样本数据中，$1,2,3,4$ 出现的频率分别为 p_1,p_2,p_3,p_4，且 $\sum_{i=1}^{4}p_i=1$，则下面四种情形中，对应样本的标准差最大的一组是

(A) $p_1=p_4=0.1,p_2=p_3=0.4$ (B) $p_1=p_4=0.4,p_2=p_3=0.1$

(C) $p_1=p_4=0.2,p_2=p_3=0.3$ (D) $p_1=p_4=0.3,p_2=p_3=0.2$

4.【2012 江西 9】样本 $(x_1,x_2,\cdots,x_n)$ 的平均数为 $\overline{x}$，样本 $(y_1,y_2,\cdots,y_m)$ 的平均数为 $\overline{y}(\overline{x}\neq\overline{y})$. 若样本 $(x_1,x_2,\cdots,x_n,y_1,y_2,\cdots,y_m)$ 的平均数 $\overline{z}=a\overline{x}+(1-a)\overline{y}$，其中 $0<a<\frac{1}{2}$，则 n,m 的大小关系为

(A) $n<m$ (B) $n>m$ (C) $n=m$ (D) 不能确定

5.【2024 新高考 II 卷 4】某农业研究部门在面积相等的 100 块稻田上种植一种新型水稻，得到各块稻田的亩产量（单位：kg）并整理得下表：

亩产量	$[900,950)$	$[950,1000)$	$[1000,1050)$
频数	6	12	18
亩产量	$[1050,1100)$	$[1100,1150)$	$[1150,1200)$
频数	30	24	10

据表中数据，下列结论中正确的是

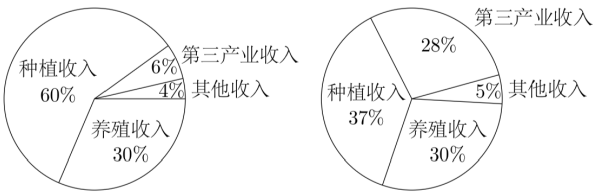
(A) 100 块稻田亩产量的中位数小于 1050 kg

(B) 100 块稻田亩产量低于 1100 kg 的稻田所占比例超过 80%

(C) 100 块稻田亩产量的极差介于 200 kg 至 300 kg 之间

(D) 100 块稻田亩产量的平均值介于 900 kg 至 1000 kg 之间

6.【2018 全国 I 卷理 3】某地区经过一年的新农村建设，农村的经济收入增加了一倍，实现翻番. 为更好地了解该地区农村的经济收入变化情况，统计了该地区新农村建设前后农村的经济收入构成比例，得到如下饼图：



则下面结论中不正确的是

(A) 新农村建设后，种植收入减少

(B) 新农村建设后，其他收入增加了一倍以上

(C) 新农村建设后，养殖收入增加了一倍

(D) 新农村建设后，养殖收入与第三产业收入的总和超过了经济收入的一半

7.【2009 上海文 18 理 17】在发生某公共卫生事件期间，专业机构认为该事件在一段时间内没有发生大规模群体感染的标志为“连续 10 日，每天新增疑似病例不超过 7 人”. 根据过去 10 天甲、乙、丙、丁四地新增疑似病例数据，一定符合该标志的是

(A) 甲地：总体均值为 3，中位数为 4　　(B) 乙地：总体均值为 1，总体方差大于 0

(C) 丙地：中位数为 2，众数为 3　　(D) 丁地：总体均值为 2，总体方差为 3

8.【湘教版必修一习题 6.6.16】一节课上，老师测量了在场所有人的身高，计算后发现男生的平均身高是 170cm，女生的平均身高是 160cm. 其中，张强是最高的，他的身高是 180cm；杜梅是最矮的，她的身高是 150cm. 那天有两名同学缺课，第二天这两人均到校上课，将这两人的身高补测，重新计算平均身高，发现女生的平均身高和男生的平均身高均未改变，可以推断

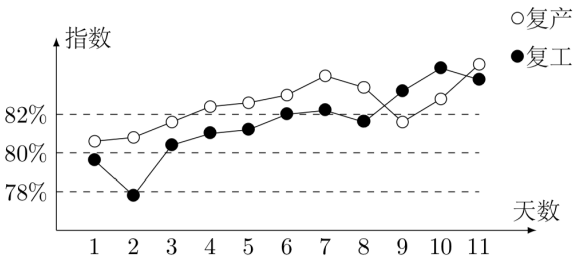
(A) 所有学生的平均身高不变

(B) 这两名学生的身高一样

(C) 这两名学生的身高不一样

(D) 如果第一天缺课的两名学生中，一名是男生，一名是女生，那么杜梅仍然是最矮的，张强仍然是最高的

9.【2020 新高考 II 卷 9】（多选）我国新冠肺炎疫情防控进入常态化，各地有序推动复工复产. 下面是某地连续 11 天的复工、复产指数折线图.



根据该折线图

(A) 这 11 天复工指数和复产指数均逐日增加

(B) 在这 11 天期间，复产指数的增量大于复工指数的增量

(C) 第 3 天至第 11 天，复工指数和复产指数都超过 80%

(D) 第 9 天至第 11 天, 复产指数的增量大于复工指数的增量

10.【2023 新高考 I 卷 9】（多选）有一组样本数据 $x_1,x_2,\cdots,x_6$，其中 x_1 是最小值，x_6 是最大值，则

(A) x_2,x_3,x_4,x_5 的平均数等于 $x_1,x_2,\cdots,x_6$ 的平均数

(B) x_2,x_3,x_4,x_5 的中位数等于 $x_1,x_2,\cdots,x_6$ 的中位数

(C) x_2,x_3,x_4,x_5 的标准差不小于 $x_1,x_2,\cdots,x_6$ 的标准差

(D) x_2,x_3,x_4,x_5 的极差不大于 $x_1,x_2,\cdots,x_6$ 的极差

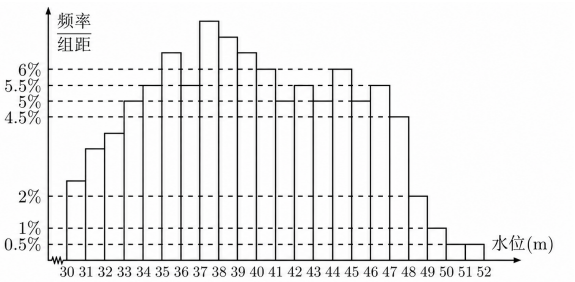
11.【2021 新高考 II 卷 9】（多选）下列统计量中可用度量样本 $x_1,x_2,\cdots,x_n$ 离散程度的有

(A) $x_1,x_2,\cdots,x_n$ 的标准差　　(B) $x_1,x_2,\cdots,x_n$ 的中位数

(C) $x_1,x_2,\cdots,x_n$ 的极差　　(D) $x_1,x_2,\cdots,x_n$ 的平均数

12.【2026 “fiddie” 模拟考 10】（多选）根据某河流观测点的若干年水位数据，得到频率分布直方图（如图）. 若 p 是河流水位大于 x 米的概率，$T=\dfrac{1}{p}$（单位：年），则称 T 为 x 米水位的重现期. 洪水等级与重现期的关系如下表.

洪水等级	重现期 T
小洪水	$T<5$
中洪水	$5\leqslant T<20$
大洪水	$20\leqslant T<50$
特大洪水	$T\geqslant 50$



用频率估计概率，估计该观测点处

(A) 47 米水位属于中洪水

(B) 特大洪水的最低水位是 48 米

(C) 50 米水位的重现期是 100 年

(D) 水位的中位数位于区间 (39,40)（单位：米）

13. 解答下述问题：

(1) 求样本数据 $2,8,14,16,20$ 第 80 分位数.

(2) **【2013 湖北文 12】**求样本 $7,8,7,9,5,4,9,10,7,4$ 的标准差.

(3) **【2009 湖南文 12】**一个总体分为 A,B 两层，用分层抽样方法从总体中抽取一个容量为 10 的样本. 已知 B 层中每个个体被抽到的概率都是 $\dfrac{1}{12}$，求总体容量.

(4) **【人教 B 版必修二复习题 5.B3】**记 $x_1\ x_2\ \ldots\ x_n$ 的平均数为 $\overline{x}$，方差为 s^2，证明：$ns^2=\sum\limits_{i=1}^{n}x_i^2-n\overline{x}^2$

(5) 叙述并证明分层（2 层）取样的平均数与方差公式，并推广到 L 层取样方差公式，即已知样本共分为 L 层、各层样本占比分别为 $w_1,w_2,\cdots w_L$、各层平均数分别为 $\overline{x_1},\overline{x_2},\cdots,\overline{x_L}$、各层方差分别为 $S_1^2,S_2^2,\cdots,S_L^2$，求样本平均数 $\overline{x}$ 与样本方差 s^2.

14. **【2014 安徽理 6】**已知样本数据 $x_1,x_2,\cdots,x_{10}$ 的标准差为 8，求数据 $2x_1-1,2x_2-1,\cdots,2x_{10}-1$ 的标准差.

15. **【2020 上海 6】**已知 $a,b,1,2$ 的中位数为 3，平均数为 4，求 ab.

16. **【2008 上海文 10 理 9】**已知总体的各个体的值由小到大依次为 $2,3,3,7,a,b,12,13.7,18.3,20$，且总体的中位数为 10.5. 若要使该总体的方差最小，求 a,b 的值.

17. **【2025 集英苑 5 月（网络联考）13】**已知样本数据 $1,4,a,a,b,6,7$ 的众数为 0，方差为 $\dfrac{48}{7}$，求该样本数据的中位数.

18. 已知 $n(n\in\mathbb{N}^*)$ 个数据 $x_1,x_2,\cdots,x_n$ 的平均数和标准差分别为 $\overline{x},S$，设 $n+1$ 个数据 $x_1,x_2,\cdots,x_n,\overline{x}$ 的标准差为 S'，判断 S 与 S' 的大小关系.

19^{U}. **【2013 辽宁文 16 理 16】**为了考察某校各班参加课外书法小组的人数，在全校随机抽取 5 个班级，把每个班级参加该小组的人数作为样本数据. 已知样本平均数是 7，样本方差是 4，且样本数据互不相同，求样本数据中的最大值.

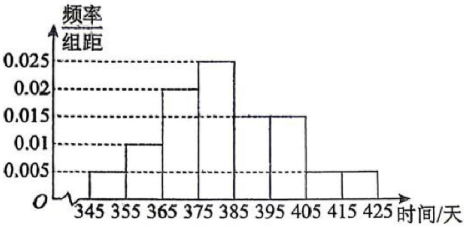
20. **【2010 安徽文 14】**某地有居民 100000 户，其中普通家庭 99000 户，高收入家庭 1000 户. 从普通家庭中以简单随机抽样方式抽取 990 户，从高收入家庭中以简单随机抽样方式抽取 100 户进行调查，发现共有 120 户家庭拥有 3 套或 3 套以上住房，其中普通家庭 50 户，高收入家庭 70 户. 依据这些数据并结合所掌握的统计知识，你认为该地拥有 3 套或 3 套以上住房的家庭所占比例的合理估计是多少?

21. **【2026 北京 17（3）】**为了解某校高三年级学生的数学学习情况，随机抽查了 200 名高三年级学生某次考试的数学成绩，整理成下表：

成绩	$[81,94)$	$[94,107)$	$[107,120)$	$[120,135)$	$[135,150]$
人数	40	60	60	32	8

为分析该校高三年级学生的数学学习情况，可采用三种方法：将样本中每名学生数学成绩所在区间的左端点值、中点值和右端点值视为该生的数学成绩．分别将这三种方法得到的三组数学成绩的方差记为 $s_{左}^2$ $s_{中}^2$ $s_{右}^2$，判断 $s_{左}^2$ $s_{中}^2$ $s_{右}^2$ 的大小关系．（结论不要求证明）

22.【2026 新高考 II 卷 15】某工厂抽取一批电子元件检测，记录第一次故障时间（天），然后绘制出如下有关“首次故障时间”的一组频率分布直方图．



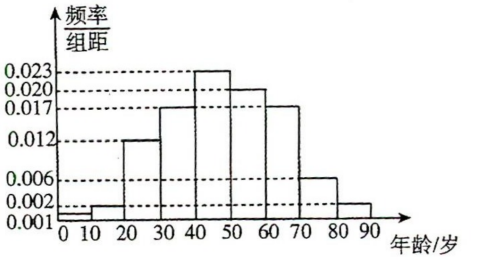
(1) 求第一四分位数和中位数；

(2) 设 p 为首次故障时间小于 365 天的概率的估计值．

i. 求 p；

ii. 已知该工厂向某用户销售了 100 件电子元件，X 为这 100 件产品首次出现故障时间小于 365 天的件数，若 $X\sim B(100,p)$，求 $E(X)$ 和 $D(X)$．

23.【2022 新高考 II 卷 19】在某地区进行流行病学调查，随机调查了 100 位某种疾病患者的年龄，得到如下频率分布直方图：

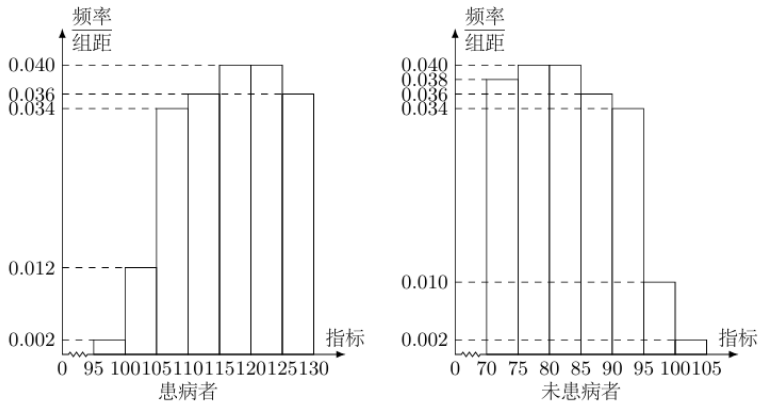


(1) 估计该地区这种疾病患者的平均年龄（同一组中的数据用该组区间的中点值为代表）；

(2) 估计该地区一位这种疾病患者的年龄位于区间 $[20,70)$ 的概率；

(3) 已知该地区这种疾病患者的患病率为 0.1%，该地区年龄位于区间 $[40,50)$ 的人口占该地区总人口的 16%。从该地区中任选一人，若此人的年龄位于区间 $[40,50)$，求此人患这种疾病的概率（以样本数据中患者的年龄位于各区间的频率作为患者的年龄位于该区间的概率，精确到 0.0001）。

24.【2023 新高考 II 卷 19】某研究小组经过研究发现某种疾病的患病者与未患病者的某项医学指标有明显差异，经过大量调查，得到如下的患病者和未患病者该指标的频率分布直方图：利用该指标制定一个检测标准，需要确定临界值 c, 将该指标大于 c 的人判定为阳性，小于或等于 c 的人判定为阴性。此检测标准的漏诊率是将患病者判定为阴性的概率，记为 $p(c)$；误诊率是将未患病者判定为阳性的概率，记为 $q(c)$. 假设数据在组内均匀分布。以事件发生的频率作为相应事件发生的概率。



(1) 当漏诊率 $p(c)=0.5\%$ 时，求临界值 c 和误诊率 $q(c)$；

(2) 设函数 $f(c)=p(c)+q(c)$. 当 $c\in[95,105]$, 求 $f(c)$ 的解析式，并求 $f(c)$ 在区间 $[95,105]$ 的最小值。

25.【2024 北京 18】某保险公司为了了解该公司某种保险产品的索赔情况，从合同保险期限届满的保单中随机抽取 1000 份，记录并整理这些保单的索赔情况，获得数据如下表：

索赔次数	0	1	2	3	4
保单份数	800	100	60	30	10

假设一份保单的保费为 0.4 万元；前三次索赔时，保险公司每次赔偿 0.8 万元；第四次索赔时，保险公司赔偿 0.6 万元. 假设不同保单的索赔次数相互独立，用频率估计概率.

(1) 估计一份保单索赔次数不少于 2 的概率；

(2) 一份保单的毛利润定义为这份保单的保费与赔偿总金额之差.

i. 记 X 为一份保单的毛利润，估计 X 的数学期望 EX；

ii. 如果无索赔的保单的保费减少 4%, 有索赔的保单的保费增加 20%, 试比较这种情况下一份保单毛利润的数学期望估计值与（i）中 EX 估计值的大小.

26.【2019 北京理 17】为了解某校学生上个月 A,B 两种移动支付方式的使用情况，从全校学生中随机抽取了 100 人，发现样本中 A,B 两种支付方式都不使用的有 5 人，样本中仅使用 A 和仅使用 B 的学生的支付金额分布情况如下：

支付方式	支付金额（元）		
	$(0,1000]$	$(1000,2000]$	大于 2000
使用 A	18 人	9 人	3 人
使用 B	10 人	14 人	1 人

已知上个月样本学生的支付方式在本月没有变化. 现从样本仅使用 A 的学生中，随机抽查 3 人，发现他们本月的支付金额都大于 2000 元. 根据抽查结果，能否认为样本仅使用 A 的学生中本月支付金额大于 2000 元的人数有变化？说明理由.

27. 某地区的公共卫生部门为调查本地区中学生的吸烟情况，随机抽样了 200 名学生，占总学生数的 1%. 调查中使用了两个问题：

问题 1：你父亲的公历生日日期是不是奇数？

问题 2：你是否经常吸烟？

每个被调查者随机从一个装有大小、形状和质量完全一样的 50 个白球和 50 个红球的袋子中摸取 1 个球（摸出的球重新放回袋中）. 摸到白球的学生如实回答第一个问题，摸到红球的学生如实回答第二个问题，回答“是”的人往一个盒子中放一个小石子，回答“否”的人什么都不要做. 调查结束后，盒子中放有 58 个小石子.

根据以上材料，估计该地区吸烟的中学生人数，并解释以上调查方法的好处.

28. 某大学计算机专业的考研人数连创新高. 今年报名刚结束，某考生想知道报考人数并计算“上岸”概率. 考生的考号按“0001,0002,...”的顺序从小到大排列. 这位考生随机了解的 50 个考生的考号如下：

0400 0904 0747 0090 0636 0714 0017 0432 0403 0276

0986 0804 0697 0419 0735 0278 0358 0434 0946 0123

0647 0349 0105 0186 0079 0434 0960 0543 0495 0974

0219 0380 0397 0283 0504 0140 0518 0966 0559 0910

0658 0442 0694 0065 0757 0702 0498 0156 0225 0327

请给出至少 2 种方法，根据这 50 个随机抽取得考号估计报考人数.

29^{U}. 上一年度某公司的 50 名员工中，最高年收入达到了 400 万元，员工年收入的平均数是 20 万元. 而你的预期是获得 18 万元年薪，正犹豫是否受聘.

(1) 是否能判断年薪为 18 万元的员工在这家公司算高收入者？并说明理由；

(2) 已知该公司员工的最低年收入是 6 万，员工收入的第一四分位数为 9 万，第三四分位数为 19 万，

i. 求员工年收入中位数的取值范围并解释其小于平均数的原因；

ii. 你将如何使用上述信息做出是否受聘的决定？

30.【2017 全国 I 卷理 19】为了监控某种零件的一条生产线的生产过程，检验员每天从该生产线上随机抽取 16 个零件，并测量其尺寸（单位：cm）. 根据长期生产经验，可以认为这条生产线正常状态下生产的零件的尺寸服从正态分布 $N\left(\mu,\sigma^2\right)$.

(1) 假设生产状态正常，记 X 表示一天内抽取的 16 个零件中其尺寸在 $(\mu-3\sigma,\mu+3\sigma)$ 之外的零件数，求 $P(X\geqslant 1)$ 及 X 的数学期望；

(2) 一天内抽检零件中，如果出现了尺寸在 $(\mu-3\sigma,\mu+3\sigma)$ 之外的零件，就认为这条生产线在这一天的生产过程可能出现了异常情况，需对当天的生产过程进行检查.

i. 试说明上述监控生产过程方法的合理性；

ii. 下面是检验员在一天内抽取的 16 个零件的尺寸：

9.95	10.12	9.96	9.96	10.01	9.92	9.98	10.04
10.26	9.91	10.13	10.02	9.22	10.04	10.05	9.95

经计算得 $\overline{x}=\dfrac{1}{16}\displaystyle\sum_{i=1}^{16}x_i=9.97, s=\sqrt{\dfrac{1}{16}\sum_{i=1}^{16}(x_i-\overline{x})^2}=\sqrt{\dfrac{1}{16}\left(\sum_{i=1}^{16}x_i^2-16\overline{x}^2\right)}\approx 0.212$，其中 x_i 为抽取的第 i 个零件的尺寸，$i=1,2,\cdots,16$. 用样本平均数 $\overline{x}$ 作为 μ 的估计值 $\hat{\mu}$，用样本标准差 s 作为 σ 的估计值 $\hat{\sigma}$，利用估计值判断是否需对当天的生产过程进行检查？剔除 $(\hat{\mu}-3\hat{\sigma},\hat{\mu}+3\hat{\sigma})$ 之外的数据，用剩下的数据估计 μ 和 σ（精确到 0.01）.

附：若随机变量 Z 服从正态分布 $N\left(\mu,\sigma^2\right)$，则 $P(\mu-3\sigma<Z<\mu+3\sigma)=0.9974$. $0.9974^{16}\approx 0.9592, \sqrt{0.008}\approx 0.09$.

1. **D.**

2. **D.** 方法一：当 $f(x)$ 取最小值时，$f'(x)=0$，即 $\sum\limits_{i=1}^{n}2(x-x_i)=0$，化简得到 $x=\dfrac{1}{n}\sum\limits_{i=1}^{n}x_i$，故最小值点为样本平均数.

方法二：$f(x)$ 是关于 x 的二次函数，配方得

$$\begin{aligned}f(x)&=\sum_{i=1}^{n}\left(x_i^2-2x_ix+x^2\right)=nx^2-2(x_1+\cdots+x_n)x+\sum_{i=1}^{n}x_i^2\\&=n\left(x-\frac{x_1+\cdots+x_n}{n}\right)^2-\frac{(x_1+\cdots+x_n)^2}{n}+\sum_{i=1}^{n}x_i^2\end{aligned}$$

所以当 $x=\dfrac{x_1+\cdots+x_n}{n}$（即为样本平均数）时，$f(x)$ 取最小值.

3. **B.**

4. **A.** 把两个样本合在一起，由平均数的定义，得

$$\overline{z}=\frac{n\overline{x}+m\overline{y}}{n+m}=\frac{n}{n+m}\overline{x}+\frac{m}{n+m}\overline{y}=\frac{n}{n+m}\overline{x}+\left(1-\frac{n}{n+m}\right)\overline{y}.$$

与题干中的 $\overline{z}=a\overline{x}+(1-a)\overline{y}$ 比较，且 $\overline{x}\neq\overline{y}$，所以 $a=\dfrac{n}{n+m}$.

因为 $0<a<\dfrac{1}{2}$，所以 $\dfrac{n}{n+m}<\dfrac{1}{2}$，即 $2n<n+m$，所以 $n<m$.

5. **C.**

6. **A.** 建设后种植收入占比由 60% 降至 37%，但总收入翻番，种植收入实际增加；其他收入由 4% 变为 5%，总收入翻番后增加一倍以上；养殖收入增加一倍；养殖和第三产业占比为 58%，超过一半. 故不正确的是 A.

7. **D.** 甲地可能不符合，反例为 $0,0,0,0,4,4,4,4,4,10$. 乙地可能不符合，反例：$0,0,0,0,0,0,0,0,1,9$. 丙地可能不符合，反例：$0,0,0,1,1,3,3,3,3,100$. 丁地符合，证明如下：设 10 天数据为 $\{x_k\}_{k=1}^{10}$（按疑似病例数从小到大排列），则 $\sum\limits_{k=1}^{10}x_k=20$. 方差 $3=\dfrac{1}{10}\sum\limits_{k=1}^{10}x_k^2-4$，即 $\sum\limits_{i=1}^{x_i^2}=70,\sum\limits_{i=1}^{x_i}=20$.

假设某天新增疑似病例不少于 8 人，为使得上述两个等式成立，这一天新增疑似病例只能为 8 人，不妨设 $x_1=8$，于是 $\sum\limits_{i=2}^{10}x_i^2=6,\sum\limits_{i=2}^{10}x_i=12$，这是无解的，于是每天新增疑似病例不超过 7 人。

相似的习题如下：

（多选）四名同学各掷骰子 5 次，分别记录每次骰子出现的点数. 根据四名同学的统计结果，可以判断一定没有出现点数 6 的是

(A) 同学甲：平均数为 3，中位数为 2　　(B) 同学乙：中位数为 3，众数为 2

(C) 同学丙：平均数为 2，方差为 2.4　　(D) 同学丁：中位数为 3，方差为 2.8

8. **D.**

9. **CD.**　注意：B 选项中，第 1 天复产与复工的差值大于第 11 天复产与复工的差值（图片上能看出微小的差别，猜测真实考卷应该会更为直观），于是复产指数的增量小于复工指数的增量，B 错误，其余选项是容易判断的。

10. **BD.**　BD 正确是显然的，AC 均可取反例。

注：对于 C 选项，可以证明当方差公式取 $s^2=\dfrac{1}{n}\sum\limits_{i=1}^{n}\left(x_i-\overline{x}\right)^2$ 时，对于样本数据 $x_1,x_2,\cdots,x_n$，删去其中的一个最大值和一个最小值后，剩余数据的方差/标准差不大于原数据的方差/标准差，证明如下：

设原数据为 $x_1\leqslant x_2\leqslant\cdots\leqslant x_{n-1}\leqslant x_n$，其中最小值为 $a=x_1$，最大值为 $b=x_n$。删去 a,b 后，剩下 $m=n-2$ 个数据，记为 $y_1,\ldots,y_m$，其平均数为 μ，方差为 s^2.

令 $c=\dfrac{a+b}{2},h=\dfrac{b-a}{2}$. 由于 $a\leqslant y_i\leqslant b$，于是 $(y_i-a)(b-y_i)\geqslant 0$. 展开并求平均，得到

$$\frac{1}{m}\sum_{i=1}^{m}y_i^2\leqslant(a+b)\mu-ab.$$

因此

$$s^2=\frac{1}{m}\sum_{i=1}^{m}y_i^2-\mu^2\leqslant(a+b)\mu-ab-\mu^2=(\mu-a)(b-\mu)\leqslant\left(\frac{b-a}{2}\right)^2=h^2.$$

下面计算原数据的方差。原数据的平均数为 $\overline{x}=\dfrac{m\mu+a+b}{m+2}$. 利用方差公式：

$$\sum_{i=1}^{n}(x_i-\overline{x})^2=ms^2+2h^2+\frac{2m}{m+2}(\mu-c)^2.$$

所以原数据的方差为

$$V_{\text{原}}=\frac{1}{m+2}\left[ms^2+2h^2+\frac{2m}{m+2}(\mu-c)^2\right].$$

于是

$$V_{\text{原}}-s^2=\frac{2}{m+2}\left[h^2+\frac{m}{m+2}(\mu-c)^2-s^2\right]\geqslant\frac{2}{m+2}\left(h^2-s^2\right)\geqslant 0.$$

因此 $V_{\text{删}}\leqslant V_{\text{原}}$. 所以，删去最小值与最大值后，方差一定不增。

11. **AC.**　统计中，反映随机变量离散程度的有：极差、方差、标准差；刻画集中趋势的有平均数、中位数、众数.

12. **ACD.**　扩充表格，把重现期对应的概率取值范围也列出来.

洪水等级	重现期 T	概率 $p=T^{-1}$
小洪水	$T<5$	$p>0.2$
中洪水	$5\leqslant T<20$	$0.05\leqslant p<0.2$
大洪水	$20\leqslant T<50$	$0.02\leqslant p<0.05$
特大洪水	$T\geqslant 50$	$p\leqslant 0.02$

对于 A 选项，水位大于 47 米的频率是 $4.5\%+2\%+1\%+0.5\%+0.5\%=8.5\%\in[0.05,0.2]$，所以 47 米水位属于中洪水. A 选项正确.

对于 B 选项，水位大于 48 米的频率是 $2\%+1\%+0.5\%+0.5\%=4\%=0.04\in[0.02,0.05]$，所以估计 48 米的水位属于大洪水，B 选项错误. 实际上可以计算出属于特大洪水的最低水位是 49 米.

对于 C 选项，根据直方图，估计河流水位大于 50 米的概率是 $0.5\%+0.5\%=1\%$，所以 50 米的河流水位的重现期是 100 年（即所谓的“百年一遇”）. C 选项正确.

对于 D 选项，水位大于 40 米的频率是 46.5%，水位在 $(39,40)$ 中的频率大于 6%，所以水位大于 39 米的频率是 52.5%. 因此水位的中位数位于区间 $(39,40)$. D 选项正确.

Fiddie 评：本题改编自**【2007 湖南文 7】**，但原题题干不够严谨，且没有提及“重现期”、“洪水等级”的概念，这些新概念取自鄂教版必修第四册的“阅读与讨论”. 问题源于实际，洪水等级与重现期的对应关系见于《水文情报预报规范》，这是真实的规范文件，可在网上查到.

13. (1) **18.**

(2) **2.**

(3) **120.** 设总体数为 N，则 $\dfrac{10}{N}=\dfrac{1}{12}$，故 $N=120$.

(4) 略。

(5) 设样本分为两层，每层样本容量分别为 n_1,n_2，其所占总样本容量的比例分别为 w_1,w_2，平均数分别为 $\overline{x}_1,\overline{x}_2$，方差分别为 S_1^2,S_2^2，合并样本的平均数求解公式为

$$\overline{x}=w_1\overline{x}_1+w_2\overline{x}_2.$$

合并样本的方差求解公式为

$$s^2=w_1\left[S_1^2+\left(\overline{x_1}-x\right)^2\right]+w_2\left[S_2^2+\left(\overline{x_2}-x\right)^2\right]$$

只对合并样本的方差求解公式进行证明：设第 i 层的第 j 个数据为 x_{ij}.

原方差为

$$s^2=\frac{1}{n_1+n_2}\left[\sum_{j=1}^{n_1}(x_{1j}-\overline{x})^2+\sum_{j=1}^{n_2}(x_{2j}-\overline{x})^2\right].$$

对于第 i 层，有

$$x_{ij}-\overline{x}=(x_{ij}-\overline{x}_i)+(\overline{x}_i-\overline{x}).$$

因此

$$\begin{aligned}\sum_{j=1}^{n_i}(x_{ij}-\overline{x})^2&=\sum_{j=1}^{n_i}[(x_{ij}-\overline{x}_i)+(\overline{x}_i-\overline{x})]^2\\&=\sum_{j=1}^{n_i}(x_{ij}-\overline{x}_i)^2+2(\overline{x}_i-\overline{x})\sum_{j=1}^{n_i}(x_{ij}-\overline{x}_i)+n_i(\overline{x}_i-\overline{x})^2.\end{aligned}$$

而 $\displaystyle\sum_{j=1}^{n_i}(x_{ij}-\overline{x}_i)=0,$，所以

$$\sum_{j=1}^{n_i}(x_{ij}-\overline{x})^2=n_iS_i^2+n_i(\overline{x}_i-\overline{x})^2.$$

对两层求和并除以总样本数，得到

$$s^2=w_1\left[S_1^2+(\overline{x}_1-\overline{x})^2\right]+w_2\left[S_2^2+(\overline{x}_2-\overline{x})^2\right]$$

推广到 L 层取样，合并样本平均数与方差求解公式分别为

$$\overline{x}=\sum_{i=1}^{L}w_i\overline{x}_i.\quad s^2=\sum_{i=1}^{L}\left[w_i\left(S_i^2+(\overline{x}_i-\overline{x})^2\right)\right]$$

推导方式同前。

14. **16.** 可知 $x_1,x_2,\cdots,x_{10}$ 的方差为 64，于是 $2x_1,2x_2,\cdots,2x_{10}$ 的方差为 $4\times64=256$，所以 $2x_1-1,2x_2-1,\cdots,2x_{10}-1$ 的方差也为 256，标准差为 $\sqrt{256}=16$.

15. **36.**

16. **10.5, 10.5.** 由条件，$a+b=21$，则这组数据的平均数是 10，所以方差为 $s^2=\dfrac{1}{10}\left[C+(a-10)^2+(b-10)^2\right]=\dfrac{a^2+b^2}{10}+C'$，其中 C,C' 是常数. 利用不等式 $2\left(a^2+b^2\right)\geqslant(a+b)^2$，等号成立当且仅当 $a=b$，可得 a,b 取值都是 10.5 时总体方差最小.

17. **3.** 因为众数是 0，所以 0 出现的次数最多，且其余数的出现次数均小于 0 的出现次数。于是至少有 2 个 0，故 a 一定等于 0. 记 $b=x$. 于是数据 $1,4,0,0,x,6,7$ 的平均数为 $\dfrac{18+x}{7}$.

由方差的变形公式 $ns^2=\sum_{i=1}^{n}x_i^2-n\overline{x}^2$，得

$$7\cdot\frac{48}{7}=\left(1+16+0+0+x^2+36+49\right)-7\left(\frac{18+x}{7}\right)^2,$$

即

$$48=102+x^2-\frac{(18+x)^2}{7}.$$

解得 $x=3$，即 $b=3$.

所以数据为 $0,0,1,3,4,6,7$，该样本数据的中位数为 3.

18. **$S'\leqslant S$.** 因为 n 个数据 $x_1,x_2,\cdots,x_n$ 的平均数为 $\overline{x}$，所以 $\sum_{i=1}^{n}\left(x_i-\overline{x}\right)^2=nS^2$.

新数据 $x_1,x_2,\cdots,x_n,\overline{x}$ 共 $n+1$ 个，它的平均数仍为 $\overline{x}$，所以它的方差为

$$S'^2=\frac{1}{n+1}\left[\sum_{i=1}^{n}\left(x_i-\overline{x}\right)^2+\left(\overline{x}-\overline{x}\right)^2\right]=\frac{n}{n+1}S^2.$$

当 $S\neq0$ 时，$S'<S$. 当 $S=0$ 时，$S'=S$。

19. **10.** 设 5 个班级参加书法小组的人数为 x_1,x_2,x_3,x_4,x_5. 不妨设 $x_1<x_2<x_3<x_4<x_5$，则 $\dfrac{1}{5}(x_1+x_2+x_3+x_4+x_5)=7$，且 $\dfrac{1}{5}\sum_{k=1}^{5}(x_k-7)^2=4$. 再次由样本数据互不相同，从而 $x_k+1\leqslant x_{k+1}$(即相邻两数相差至少为 1). 所以 $x_5\geqslant x_1+4,x_5\geqslant x_2+3,x_5\geqslant x_3+2,x_5\geqslant x_4+1$. 所以 $35=x_1+x_2+x_3+x_4+x_5\leqslant-10+5x_5\Rightarrow x_5\geqslant9$. 又由于 $(x_5-7)^2<\sum_{k=1}^{5}(x_k-7)^2=16$，从而 $x_5<11$. 则 $x_5\in\{9,10\}$.

(1) 如果 $x_5=10$，则 $x_1+x_2+x_3+x_4=25$，为奇数，且 $\sum_{k=1}^{4}(x_k-7)^2=11$，而 11 写成四个数的平方和只可能为 $11=0^2+1^2+1^2+3^2$，所以 $x_1=4,x_2=6,x_3=7,x_4=8$.

（2）如果 $x_5=9$，则 $x_1+x_2+x_3+x_4=26$，为偶数，且 $\sum\limits_{k=1}^{4}(x_k-7)^2=16$，而 16 写成 4 个数的平方和只可能为 $16=2^2+2^2+2^2+2^2$ 或 $16=0^2+0^2+0^2+4^2$，这两种情况都会产生相同样本数据，矛盾.

因此样本数据中的最大值为 10.

20. **5.7%** 普通家庭中估计有 $99000\times\dfrac{50}{990}=5000$ 户，高收入家庭中估计有 $1000\times\dfrac{70}{100}=700$ 户，共 5700 户，故比例为 $\dfrac{5700}{100000}=5.7\%$.

21. $s_{左}^2<s_{中}^2<s_{右}^2$. 所有数据加上相同的数时，方差不变。将左端点值改为中点值时，前三组均增加 6.5，后两组均增加 7.5，先对所有数据加 6.5，方差不变，需要分析的是：只对最后两组增加 1 会如何影响方差，直观猜测，这一操作将使得数据更为分散，方差增大。

较为严格的解释如下：设数据分成两部分：A：不移动；B：整体向右移动 $d>0$。设两部分人数占比分别为 p,q，两部分原来的平均数分别为 μ_A,μ_B. 原来的方差分别为 s_A^2,s_A^2.

先证明整体方差 $S^2=ps_A^2+qs_B^2+pq(\mu_B-\mu_A)^2$

由分层取样方差公式有

$$S^2=p[s_A^2+(\mu_1-p\mu_1-q\mu_2)]+q[s_B^2+(\mu_2-p\mu_1-q\mu_2)]$$

化简即可得到上式。

如果把 B 中所有数据都加上 d，则 μ_B 增加 d，s_B^2 不变，可以算出新旧方差之差为

$$s_{新}^2-s_{旧}^2=pq\left[2d(\mu_B-\mu_A)+d^2\right].$$

B 是右边的高分组，那么 $\mu_B>\mu_A$. 于是 $2d(\mu_B-\mu_A)+d^2>0$，必有

$$\boxed{s_{新}^2>s_{旧}^2}.$$

22. （1）第一四分位数为 370，中位数为 381.

（2.i）0.15；（2.ii）$E(X)=15$，$D(X)=12.75$.

23. （1）47.9(岁)

（2）0.89

（3）设事件 B 表示“任选一人，此人年龄位于区间 $[40,50)$”，事件 C 表示“任选一人，此人患这种病”，则由条件概率公式可得 $P(C|B)=\dfrac{P(BC)}{P(B)}=\dfrac{0.1\%\times0.023\times10}{16\%}=\dfrac{0.001\times0.23}{0.16}=0.0014375\approx0.0014$

24. （1）患病者指标不大于 97.5 的频率为 $0.002\times(97.5-95)=0.5\%$，故 $c=97.5$. 未患病者指标大于 97.5 的频率为

$$q(97.5)=0.010\times(100-97.5)+0.002\times(105-100)=3.5\%$$

（2）当 $95\leqslant c<100$ 时，

$$f(c)=0.002(c-95)+0.010(100-c)+0.002(105-100)=0.82-0.008c$$

当 $100\leqslant c\leqslant105$ 时，

$$f(c)=0.002(100-95)+0.012(c-100)+0.002(105-c)=0.01c-0.98$$

所以

$$f(c)=\begin{cases}0.82-0.008c & c\in[95,100)\\ 0.01c-0.98 & c\in[100,105]\end{cases}.$$

$f(c)$ 在 $[95,100]$ 上递减，在 $[100,105]$ 上递增，故最小值为 $f(100)=0.02$.

25. (1) 设一份保单索赔次数为 Y，则

$$P(Y\geqslant 2)=P(Y=2)+P(Y=3)+P(Y=4)=\frac{60}{1000}+\frac{30}{1000}+\frac{10}{1000}=\frac{1}{10}.$$

因此，一份保单索赔次数不少于 2 的概率为 $\dfrac{1}{10}$。

(2.i) X 的可能取值为 $0.4,-0.4,-1.2,-2,-2.6$，则

$$P(X=0.4)=\frac{800}{1000}=\frac{4}{5},P(X=-0.4)=\frac{100}{1000}=\frac{1}{10},P(X=-1.2)=\frac{60}{1000}=\frac{3}{50},$$
$$P(X=-2)=\frac{30}{1000}=\frac{3}{100},P(X=-2.6)=\frac{10}{1000}=\frac{1}{100}.$$

于是 $\mathrm{E}(X)=0.4\times\dfrac{4}{5}-0.4\times\dfrac{1}{10}-1.2\times\dfrac{3}{50}-2\times\dfrac{3}{100}-2.6\times\dfrac{1}{100}=0.122$

(2.ii) 保单的保费调整后，无索赔保单的保费为 0.384 万元，有索赔保单的保费为 0.48 万元。毛利润 X 的可能取值为 $0.384,-0.32,-1.12,-1.92,-2.52$，此时

$$\mathrm{E}(X)=0.384\times\frac{4}{5}-0.32\times\frac{1}{10}-1.12\times\frac{3}{50}-1.92\times\frac{3}{100}-2.52\times\frac{1}{100}=0.1252.$$

因此，调整后的保单毛利润的数学期望的估计值大于调整前的保单毛利润数学期望的估计值。

26. 记事件 E 为“从样本仅使用 A 的学生中随机抽查 3 人，他们本月的支付金额都大于 2000 元”。假设样本仅使用 A 的学生中，本月支付金额大于 2000 元的人数没有变化，则由上个月的样本数据得

$$P(E)=\frac{1}{\mathrm{C}_{30}^{3}}=\frac{1}{4060}.$$

因为 $P(E)$ 比较小，概率比较小的事件一般不容易发生。一旦发生，就有理由认为本月的支付金额大于 2000 元的人数发生了变化，所以可以认为有变化。

27. 1600 人；该调查方法能较好保护被调查者隐私，减轻其顾虑，从而更容易获得较真实的调查结果.

评：通过调查获取数据的基本方式是询问，无论是面对面的调查，如入户调查，还是非面对面的调查，如电话调查、网络调查等，调查问卷都是必需的.

在中学阶段，对统计学参数估值板块的考察往往侧重于分析数据，这使得许多中学生未能意识到数据收集的重要性与艺术性. 事实上，在人文社科领域，能否实现数据的收集、能否收集到“好”的数据往往决定一个研究的成败——设计问卷作为一种收集高质量数据的常用手段，有很大的学问.

例如，调查问题的措辞会对被调查者产生影响：在调查人们购买汽车的意愿时，使用“很多人都要买汽车，您呢?”这一问题是极不妥的，它带有明显的引导性，应当改为“您最近打算买汽车吗?”. 再如，问题在问卷中的位置也会对被调查者产生影响. 一般比较容易的、不涉及个人隐私情况的问题应当排在靠前的位置，较难的、涉及个人隐私的问题应排得靠后. 除此以外，对一些敏感性问题的调查，例如社区家庭暴力现象、单位是否违规经营、学生在考试中是否作弊等，更

要精心设计问卷及调查方法，设法消除被调查者的顾虑，使他们能够如实回答问题. 否则，被调查者往往会拒绝回答，或不提供真实情况.

不妨看下面这个例子：某校高二年级共有 360 名学生. 为了了解该年级的学生在做数学作业前是否先复习相关的课堂内容，老师要进行一次抽样调查. 如果已经用随机抽样的方式抽到了 100 个学生的学号，试问以下哪种调查方案较好?

（A）老师在课堂上询问并记录这 100 名学生的情况.

（B）采用问卷的方式对这 100 名学生进行调查. 只需要他们在匿名问卷上打钩，然后请被调查者将问卷交给老师.

（C）采用和 B 相同的调查方案，但是告诉被调查者要调查 100 名学生，而且让他们将答卷折叠后投入封闭的投票箱，全部调查完毕后再开箱统计.

（D）将 B 中的问卷夹入各自的数学作业本中上交.

由于部分学生不愿意让别人知道自己在做作业前是否先复习相关的课堂内容，所以调查时应当让被调查者知道他的回答会得到保密. 只有这样，调查才有可能获得事实真相. 按照这个原则，方案 C 是其中较好的方案. 方案 A 忽略了被调查者的感受，容易得到有偏差的结果. 方案 B 和 D 忽略了有的被调查者不愿让老师知道自己的真实情况，因而可能不回答事实真相.

除此以外，提问内容还有诸多需要注意的方面. 比方说，提问的内容要简单明确. 提问太长，会给回答带来困难和引起被调查者的反感，不利于得到正确的回答. 提问的用词要确切，通俗易懂，有礼貌，不用引导词语. “您用什么牌子的牙膏?”这句话时间范围不明确，应改为“您现在用什么牌子的牙膏?”.

28. 方法一：用样本最大值估计总体最大编号，样本中的最大考号为 0986，故可估计报考人数约为 986；

方法二：用样本平均数估计总体平均编号，若编号从 1 到 N 连续排列，则总体平均编号约为 $\dfrac{N+1}{2}$，由数据可得样本平均数 $\overline{x}=491.42$，据此估计报考人数约为 983 人.

评：这一问题出自著名的德军坦克问题. 二战期间，盟军一直在努力确定德军坦克的生产速度，为获取此数据，盟军通过传统间谍情报网络与统计学两种方法进行了估算，下表是战后缴获的德军真实生产纪录、统计学估值与常规间谍情报估值的数据：

月份	常规间谍情报估值	统计学估值	德军实产量（战后解密）
1940 年 6 月	1000 辆	169 辆	122 辆
1941 年 6 月	1550 辆	244 辆	271 辆
1942 年 8 月	1550 辆	327 辆	342 辆

常规情报部门（审讯战俘、侦察机航拍、解密电报等）严重夸大了德军的产能，而统计学估算则极其贴近真实情况.

为什么会统计学估算可以如此准确呢?

原来，德军在制造坦克时秉承了严谨的工业管理传统，他们对每一个关键部件（发动机、变速箱、底盘等）都进行了连续的、从 1 开始的正整数序列号标记. 当盟军在战场上击毁、俘获德军坦克，

或者从废弃厂房中获得坦克零件时，统计学家收集了这些序列号，以此来估算德军的坦克总产量.

假设德军某月生产的坦克总数为 N，缴获的该月生产的 k 辆坦克编号从小到大为 $x_1,x_2,\cdots,x_k$，记 $m=x_k$，即它们之中的最大值，要利用 k 和 m 来估计 N .

这里我们使用矩估计,这是一种用“样本矩”去匹配“总体矩”的参数估计方法. 此处 $M=\max\{x_1,x_2,\cdots,x_k\}$，样本矩是 m，下求解总体矩：

$$E(M)=\sum_{m=k}^{N} m\cdot P(M=m)=\sum_{m=k}^{N} m\frac{\mathrm{C}_{m-1}^{k-1}}{\mathrm{C}_N^k}=\frac{k(N+1)}{k+1}$$

解出 $N=\dfrac{k+1}{k}E(M)-1$

29. (1) 不能判断. 因为 400 万元远高于平均数 20 万元，说明这家公司的年收入数据中有少数极端大的值把平均数拉高了，而题干既没有给出 “高收入者” 的标准，也没有给出中位数、四分位数等反映一般水平的量，所以仅凭平均数不能判断 18 万元在这家公司处于什么位置.

(2) (i) 把 50 名员工的年收入按从小到大排列. 第一四分位数 9 万元表示有 25% 的数据不超过它，第三四分位数 19 万元表示有 75% 的数据不超过它，而中位数 M 是居于中间位置的数，它介于第一四分位数与第三四分位数之间，所以

$$9\leqslant M\leqslant 19,$$

即中位数的取值范围是 $[9,19]$（单位：万元）. 例如数据为 6 万元、9 万元各若干、19 万元各若干再加一个 400 万元时，这两个端点都可以取到，所以这个范围不能再缩小.

中位数不超过平均数，是因为少数员工的年收入特别高（最高达到 400 万元），把这些极端大的值计入后平均数被拉高；而中位数只反映中间位置，不受极端值影响.

(ii) 平均数容易受极端值影响，判断收入处于什么水平应主要看中位数与四分位数. 因为 18 万元低于第三四分位数 19 万元，说明公司中约有 75% 的员工年收入不超过 19 万元，18 万元的年薪已处在较高的一档. 所以可以接受这份工作.

30. (1) 抽取的一个零件的尺寸在 $(\mu-3\sigma,\mu+3\sigma)$ 之内的概率为 0.9974，从而零件尺寸在该区间之外的概率为 0.0026，故 $X\sim B(16,0.0026)$，因此 $P(X\geqslant 1)=1-P(X=0)=1-0.9974^{16}\approx 0.0408$ X 的数学期望为 $E(X)=16\times 0.0026=0.0416$

(2.i) 如果生产状态正常，一个零件尺寸在 $(\mu-3\sigma,\mu+3\sigma)$ 之外的概率只有 0.0026，一天内抽取的 16 个零件中，出现尺寸在该区间之外的零件的概率只有 0.0408，发生的概率很小。因此一旦发生这种情况，就有理由认为这条生产线在这一天的生产过程可能出现了异常情况，需对当天的生产过程进行检查，可见上述监控生产过程的方法是合理的。

(2.ii) 由 $\overline{x}=9.97$，$s\approx 0.212$，得 μ 的估计值为 $\widehat{\mu}=9.97$，σ 的估计值为 $\widehat{\sigma}=0.212$。由样本数据可以看出有一个零件尺寸在 $\left(\widehat{\mu}-3\widehat{\sigma},\widehat{\mu}+3\widehat{\sigma}\right)$ 之外，因此需对当天的生产过程进行检查。

剔除区间 $\left(\widehat{\mu}-3\widehat{\sigma},\widehat{\mu}+3\widehat{\sigma}\right)$ 之外的数据 9.22，剩下数据的平均数为 $\dfrac{1}{15}(16\times 9.97-9.22)=10.02$ 因此 μ 的估计值为 10.02。又

$$\sum_{i=1}^{16}x_i^2=16\left(s^2+\overline{x}^{,2}\right)=16\times 0.212^2+16\times 9.97^2\approx 1591.134$$

剔除区间之外的数据 9.22，剩下数据的方差为

$$\frac{1}{15}\left(1591.134-9.22^2-15\times 10.02^2\right)\approx 0.008$$

因此 σ 的估计值为 $\sqrt{0.008}\approx 0.09$.