第十章 概率与统计

10.5 成对数据的统计分析

10.5.1 成对数据的统计相关性

函数关系 $y=f(x)$ 中，自变量与因变量具有确定的对应关系，而在现实生活中，两个变量之间的关系往往没那么简单，例如农业生产中，农作物产量与施肥量之间的关系；商业活动中，广告费支出与销售量之间的关系……如果两个变量取值的关系存在某种规律性，但又没有确切到可由其中一个去精准地决定另一个的程度，那么称这两个变量之间存在**相关关系**. 例如，居民家庭储蓄与家庭收入存在相关关系，这是因为在通常情况下，家庭储蓄额随着家庭收入的增加而增加，但家庭收入并不是决定居民家庭储蓄的唯一因素。

我们通常会根据自己以往的经验对上述相关关系进行分析，所谓“经验之中有规律”，它的确可以为我们的决策提供一定的依据。但仅凭经验推定未免太过武断——不同经验的人会对同一情形得出不同结论，不是所有的情形都有经验可循等等。因此在研究两个变量的相关关系时，我们更多地是用数据说话，即通过对一系列预先获取到的成对观测数据进行分析、提取信息、构建模型，以揭示两个变量之间的潜在关系.

通常用**散点图**来直观展示样本数据的分布情况. 将这两个变量的观测值分别作为横、纵坐标，每一个成对数据对应图上的一个点. 如果从整体上看，当一个变量的值增加时，另一个变量的相应值也呈现增加的趋势，则称这两个变量**正相关**；如果另一个变量的相应值呈现减少的态势，则称这两个变量**负相关**；如果两个变量近似地表现为线性关系，则称它们有**线性相关关系**.

10.5.2 样本相关系数

通过观察散点图中成对样本数据的分布规律，我们可以大致推断两个变量是否线性相关. 散点图虽然直观，但不能准确反映成对样本数据之间的相关程度. 因此考虑引入一个叫“样本相关系数”的度量指标.

回顾随机变量相关系数的公式[1]：

$$\rho_{X,Y}=\frac{\operatorname{Cov}(X,Y)}{\sqrt{DX}\sqrt{DY}}=\frac{EXY-EXEY}{\sqrt{DX}\sqrt{DY}}$$

对于变量 x,y 的成对样本数据 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$，可以认为参数 x 等可能地在 $x_1,\cdots,x_n$ 中取，参数 y 等可能地在 $y_1,\cdots,y_n$ 中取，类比随机变量相关系数公式可以得

[1] 如果没有学习随机变量相关系数公式的概念，可以跳过该段，不影响后续阅读与理解。

到

$$r_{xy}=\frac{\sum\limits_{i=1}^{n}\left(x_i-\overline{x}\right)\left(y_i-\overline{y}\right)}{\sqrt{\sum\limits_{i=1}^{n}\left(x_i-\overline{x}\right)^2}\sqrt{\sum\limits_{i=1}^{n}\left(y_i-\overline{y}\right)^2}}=\frac{\sum\limits_{i=1}^{n}x_iy_i-n\overline{x}\overline{y}}{\sqrt{\sum\limits_{i=1}^{n}x_i^2-n\overline{x}^2}\sqrt{\sum\limits_{i=1}^{n}y_i^2-n\overline{y}^2}}$$

定义 r_{xy} 为变量 x 与变量 y 的**样本相关系数**.

如果考虑向量 $\boldsymbol{u}=(x_1-\overline{x},x_2-\overline{x},\cdots,x_n-\overline{x})$,$\boldsymbol{v}=(y_1-\overline{y},y_2-\overline{y},\cdots,y_n-\overline{y})$，回顾第二章对 n 维向量的数量积与夹角的余弦值 $\cos\theta$ 的定义，则上述相关系数可记作

$$r=\cos\langle\boldsymbol{u},\boldsymbol{v}\rangle=\frac{\boldsymbol{u}\cdot\boldsymbol{v}}{|\boldsymbol{u}|\,|\boldsymbol{v}|}=\frac{\sum\limits_{i=1}^{n}\left(x_1-\overline{x}\right)\left(y_1-\overline{y}\right)}{\sqrt{\sum\limits_{i=1}^{n}\left(x_i-\overline{x}\right)^2}\sqrt{\sum\limits_{i=1}^{n}\left(y_i-\overline{y}\right)^2}}$$

其取值范围是 $[-1,1]$.

样本相关系数具有下述性质：

（1）$|r_{xy}|\leqslant 1$，当 $0<r_{xy}\leqslant 1$ 时，称变量 x 与变量 y 正相关；当 $-1\leqslant r_{xy}<0$ 时，称变量 x 与变量 y 负相关；

（2）$|r_{xy}|$ 越接近 1，变量 x 与变量 y 的线性相关程度越高，这时样本数据分布在一条直线附近，得出的回归直线方程也越有价值。$|r_{xy}|=1$ 的充要条件是成对数据构成的点都在回归直线上；$|r_{xy}|$ 越接近 0，变量 x 与变量 y 的线性相关程度越低，此时得出的回归直线方程越没有价值；

（3）r_{xy} 具有对称性，“y 与 x 的相关系数” 等价于 “x 与 y 的相关系数”，即 $r_{xy}=r_{yx}$；

（4）r_{xy} 仅仅是变量 x 与变量 y 之间线性相关程度的一个度量，r_{xy} 只表示两个变量之间不存在线性相关关系，并不说明变量之间没有关系，它们可能存在非线性关系.

（5）与随机变量的相关系数一样，样本相关系数与样本的单位无关，即在改变单位使得数据本身放大或缩小若干倍的情况下，样本相关系数不会改变；

（6）与平均数和标准差一样，样本相关系数不仅会受到数据量多少的影响，也会受到少量较大异常值的影响.

10.5.3　一元线性回归模型

对于存在相关关系的随机变量，人们希望运用统计方法，建立适当的统计模型来较为准确地刻画这一规律，并通过模型进行新数据的预测. 这类规律在统计学中被称为**回归关系**. 有关回归关系的计算理论及方法被称为**回归分析**. 它已发展为统计学的一个重要分支，在社会生产生活及科学研究中都有着广泛应用.

以儿子与父亲的身高关系为例，生活经验告诉我们，这二者的身高大致呈正线性相关，因此可以尝试用一次函数来刻画父亲身高对儿子身高的影响，把其他影响儿子身高的因素，如

母亲身高、生活环境、饮食习惯等作为随机误差，得到刻画两个变量之间关系的线性回归模型，其中，随机误差是一个随机变量。

用 x 表示父亲身高，Y 表示儿子身高，e 表示随机误差，假定随机误差 e 的均值为 0，方差为与父亲身高无关的定值 σ^2，则它们之间的关系可以表示为

$$\begin{cases} Y = bx + a + e, \\ E(e) = 0, D(e) = \sigma^2. \end{cases}$$

称该式为 Y 关于 x 的**一元线性回归模型**[2]，其中 Y 称为**因变量**或**响应变量**，x 称为**自变量**或**解释变量**；a, b 称为模型的未知参数。

要确定未知参数 a, b，相当于寻找一条适当的直线，使得表示成对样本数据的这些散点在整体上与该直线最“贴近”，凭直觉是很难断定的，我们希望基于一个“贴近标准”，明确回归直线方程的求解方法.

现给定一组有线性相关关系的成对数据 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ 与一个线性方程 $y = a + bx$，怎么描述数据与此回归直线方程的贴近度呢？对于每一个自变量 x_i，我们把实际**观测值** y_i 与通过该直线方程计算得到的**预测值** $a + bx_i$ 的差值称为第 i 个数据的**残差**，记为 e_i. 残差的绝对值即反映了此数据与直线的“差距”，我们应当选取理想的参数 a, b，使得所有残差的绝对值之和尽可能小. 应当注意的是，残差绝对值之和这一衡量标准虽然在数学上是合理的，但实际计算起来很不方便，通常考虑使用残差平方和进行替代[3]，即通过确定 a, b 的取值以最小化

$$\sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - (a + bx_i))^2$$

设 $Q(a, b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2$，有（其中 ε 为不含 a, b 项的无关常数）有

$$\begin{aligned} Q(a, b) &= \sum_{i=1}^{n} (y_1^2 + a^2 + b^2 x_i^2 - 2ay_i - 2bx_i y_i + 2abx_i) \\ &= (na^2 - 2n\overline{y}a + 2n\overline{x}ba) + (\sum_{i=1}^{n} x_i)b^2 - 2(\sum_{i=1}^{n} x_i y_i)b + \varepsilon \\ &= n(a - \overline{y} + b\overline{x})^2 + (\sum_{i=1}^{n} x_i^2 - n\overline{x}^2)b^2 + 2(\sum_{i=1}^{n} x_i y_i - n\overline{x} \cdot \overline{y})b + \varepsilon \end{aligned}$$

---

[2]假定 e 的均值为 0 是为了标准化。如果随机误差的均值为 $d(d \neq 0)$，那么可以修改截距 a' 为 $a - d$，将这一非零均值吸收。假定方差为与父亲身高无关的定值 σ^2：σ^2 越小，意味着数据越紧密地围绕回归直线；σ^2 越大，意味着数据越分散，当 σ^2 与父亲身高无关时，数据如同等宽的带子一般均匀地散在回归直线附近，否则可能会呈现出喇叭形或其他混乱形态。该模型的意思是，对于父亲身高为 x 的人群，儿子身高不是一个确定值，而是在平均水平 $bx + a$ 附近随机波动；这种随机波动平均而言既不偏高也不偏低，并且在不同父亲身高水平下，其波动程度大致相同。

[3]这一优化目标可导，是凸函数，且对离群点敏感度较高（平方级增长）

由于二次函数在顶点处取到最值，于是当

$$\hat{b}=\frac{\sum\limits_{i=1}^{n}x_iy_i-n\overline{xy}}{\sum\limits_{i=1}^{n}x_i^2-n\overline{x}^2}=\frac{\sum\limits_{i=1}^{n}\left(x_i-\overline{x}\right)\left(y_i-\overline{y}\right)}{\sum\limits_{i=1}^{n}\left(x_i-x\right)^2},\hat{a}=\overline{y}-\hat{b}\overline{x}$$

时，$Q\left(a,b\right)$ 取到最小值.

我们将 $\hat{y}=\hat{a}+\hat{b}x$ 称为 y 关于 x 的**一元线性回归方程**或**线性回归方程**. 我们的回归分析是基于 $Q\left(a,b\right)$ 取最小值的假设，这种回归分析的方法称为**最小二乘法**（Least Squares Method），求得的 $\hat{a},\hat{b}$ 称为模型参数 a,b 的**最小二乘估计**.

由于随机误差的影响，实际的样本点通常不会全部落在回归直线上，如果该回归方程的描述效果较好，那么这些样本点应该大致分布在回归直线的两侧. 为便于研究，人们考虑对残差进行分析，此时，经一求得的回归方程计算得到某自变量对应的残差，用自变量作为横坐标，残差作为纵坐标，可以绘制残差图。若该回归方程的描述效果较好，残差将比较均匀地分布在横轴的两边，这说明残差比较符合一元线性回归模型的假定，是均值为 0，方差为 σ^2 的随机变量的观测值。这种通过分析残差判断模型刻画数据的效果，以及判断原始数据中是否存在可疑数据等方面的工作称为**残差分析**.

对于某个给定的新的自变量值，一元线性回归方程可用于预测其对应的因变量值. 在使用经验回归方程进行预测时，需要注意如下问题：

（1）经验回归方程只适用于所研究的样本的总体。例如，根据我国父亲身高和儿子身高的数据建立的经验回归方程，不能用来描述美国父亲身高与儿子身高之间的关系。

（2）经验回归方程一般具有时效性。例如，根据 20 世纪 80 年代的父亲身高和儿子身高的数据建立的经验回归方程，不能用来描述现在的父亲身高和儿子身高之间的关系。

（3）解释变量的取值不能离样本数据的范围太远。例如，上述数据中父亲的身高范围大致为 $[160,200]$（单位：厘米），对于身高为 250 厘米的父亲，用该回归方程预测其儿子身高的效果是很差的。

（4）不能期望经验回归方程得到的预报值就是响应变量的精确值，事实上，它是响应变量的可能取值的平均值。

对于非线性回归关系的参数求解，可以考虑做变量代换，使新变量之间的关系可以被视为线性关系，以模型 $y=c_1+c_2\ln(t-1985)$（其中 c_1,c_2 是参数）为例，令 $x=\ln(t-1985)$，通过已有数据求出 x_i,y_i，用最小二乘法求出 y 关于 x 的线性回归方程，最后还原到原先的变量即可。

比较两个回归方程模型的拟合效果有如下方法。

方法一：分别计算两个模型的残差平方和，残差平方和较小的模型拟合效果更好，

方法二：比较**决定系数** R^2，其计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y_i})^2}{\sum_{i=1}^{n}(y_i - \overline{y})^2}$$

在 R^2 表达式中，$\sum_{i=1}^{n}(y_i - \overline{y})^2$ 与经验回归方程无关，残差平方和 $\sum_{i=1}^{n}(y_i - \hat{y_i})^2$ 与经验回归方程有关。因此 R^2 越大，表明残差平方和越小，即模型的拟合效果越好。

用最小二乘法求解得到的一元线性回归方程的 R^2 取值范围是 $[0,1]$。当 $R^2 = 1$ 时，残差平方和为 0，这表明所有数据均落在回归直线上。当 $R^2 = 0$ 时，$\sum_{i=1}^{n}(y_i - \hat{y_i})^2 = \sum_{i=1}^{n}(y_i - \overline{y})^2$，满足该情况的一条回归直线是 $y = \overline{y}$，而最小二乘法的求解目标是最小化残差平方和，求解得到的回归直线的残差平方和一定不超过 $\sum_{i=1}^{n}(y_i - \overline{y})^2$，因此 $R^2 \geqslant 0$。[4]

方法三：用新的观测数据来检验模型的拟合效果，如果新数据仍然落在回归方程 I 附近，而原理回归方程 II，则认为回归方程 I 对新数据的预报效果要远远好于 II。

[4] 分母用 $\sum_{i=1}^{n}(y_i - \overline{y})^2$，这代表了一种拟合方式，即对所有数据都用 $\overline{y}$ 进行预测，这显然是奇差无比的。

第十章 概率与统计

10.5 成对数据的统计分析

习 题

A 组

1.【沪教版选必修二练习 8.2(1).2】两个变量 x 与 y 之间的回归方程

(A) 表示 x 与 y 之间的函数关系

(B) 表示 x 与 y 之间的不确定关系

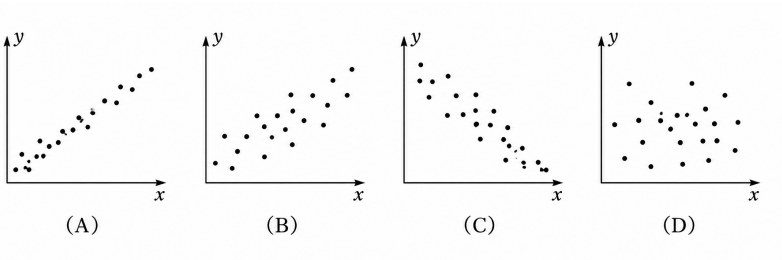
(C) 反映 x 与 y 之间的真实关系

(D) 是反映 x 与 y 之间的真实关系的一种最佳拟合

2.【沪教版选修二练习 8.2(1).3】用最小二乘法求回归方程是为了使

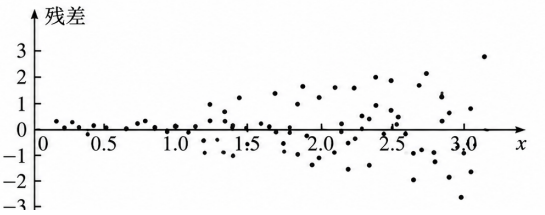
(A) $\sum\limits_{i=1}^{n}\left(y_i-\overline{y}\right)=0$ (B) $\sum\limits_{i=1}^{n}(y_i-\hat{y}_i)=0$ (C) $\sum\limits_{i=1}^{n}(y_i-\hat{y}_i)$ 最小 (D) $\sum\limits_{i=1}^{n}(y_i-\hat{y}_i)^2$ 最小

3.【2024 天津 3】下列图中，相关系数最大的是



(A) 图 A (B) 图 B (C) 图 C (D) 图 D

4.【人教 A 版选修三复习参考题 8.2】根据变量 Y 和 x 的成对样本数据，由一元线性回归模型 $\begin{cases}Y=bx+a+e,\\ E(e)=0,\quad D(e)=\sigma^2\end{cases}$ 得到经验回归模型 $\hat{y}=\hat{b}x+\hat{a}$ 对应的残差如图所示．模型误差



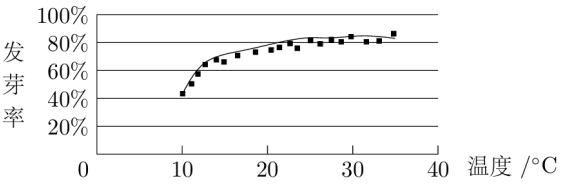
(A) 满足一元线性回归模型的所有假设

(B) 不满足一元线性回归模型的 $E(e)=0$ 的假设

(C) 不满足一元线性回归模型的 $D(e)=\sigma^2$ 的假设

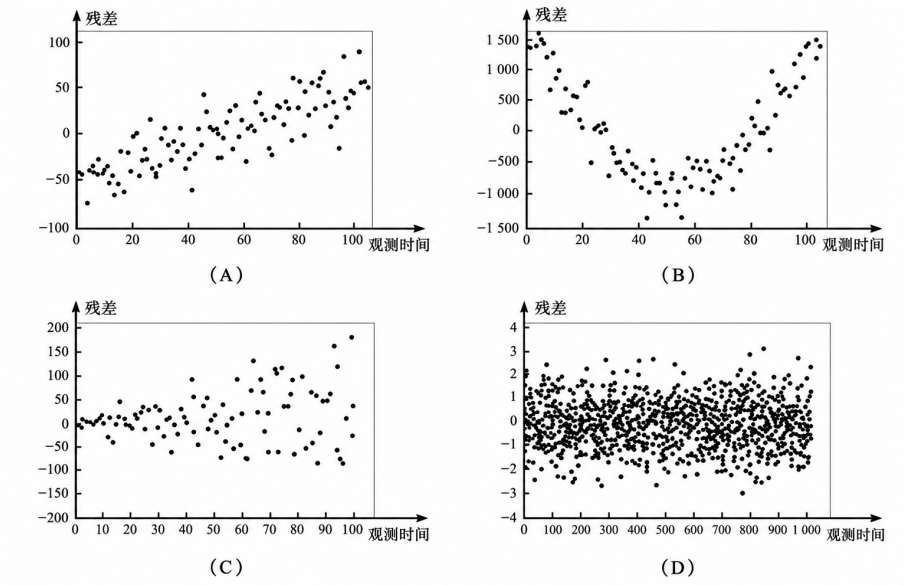
(D) 不满足一元线性回归模型的 $E(e)=0$ 和 $D(e)=\sigma^2$ 的假设

5.【2020 全国 I 卷理 5】某校一个课外学习小组为研究某作物种子的发芽率 y 和温度 x（单位：°C）的关系，在 20 个不同的温度条件下进行种子发芽实验，由实验数据 (x_i,y_i)（$i=1,2,\ldots,20$）得到下面的散点图（图略）。由此散点图，在 10°C 至 40°C 之间，下面四个回归方程类型中最适宜作为发芽率 y 和温度 x 的回归方程类型的是



(A) $y=a+bx$　　(B) $y=a+bx^2$　　(C) $y=a+be^x$　　(D) $y=a+b\ln x$

6.【人教 A 版选修三第 112 页思考】对于下述四幅残差图，哪一个残差满足一元线性回归模型中对随机误差的假定



7.【2015 湖北文 4】已知变量 x 和 y 满足关系 $y=-0.1x+1$，变量 y 与 z 正相关. 下列结论中正确的是

(A) x 与 y 正相关，x 与 z 负相关　　(B) x 与 y 正相关，x 与 z 正相关

(C) x 与 y 负相关，x 与 z 负相关　　(D) x 与 y 负相关，x 与 z 正相关

8. **【2011 江西 6】**变量 X 与 Y 相对应的一组数据为 $(10,1),(11.3,2),(11.8,3),(12.5,4),(13,5)$；变量 U 与 V 相对应的一组数据为 $(10,5),(11.3,4),(11.8,3),(12.5,2),(13,1)$.$r_1$ 表示变量 Y 与 X 之间的线性相关系数，r_2 表示变量 V 与 U 之间的线性相关系数，则

(A) $r_2<r_1<0$　　(B) $0<r_2<r_1$　　(C) $r_2<0<r_1$　　(D) $r_2=r_1$

9. **【2011 陕西文 9 理 9】**设 (x_1,y_1)，(x_2,y_2)，$\cdots$，(x_n,y_n) 是变量 x 和 y 的 n 个样本点，直线 l 是由这些样本点通过最小二乘法得到的线性回归直线（如图），以下结论正确的是

(A) x 和 y 的相关系数为直线 l 的斜率

(B) x 和 y 的相关系数在 0 到 1 之间

(C) 当 n 为偶数时，分布在 l 两侧的样本点的个数一定相同

(D) 直线 l 过点 $(\overline{x},\overline{y})$

10. **【2013 福建文 11】**已知 x 与 y 之间的几组数据如下表:

x	1	2	3	4	5	6
y	0	2	1	3	3	4

假设根据上表数据所得线性回归直线方程为 $\hat{y}=\hat{b}x+\hat{a}$. 若某同学根据上表中的前两组数据 $(1,0)$ 和 $(2,2)$ 求得的直线方程为 $y=b'x+a'$，则以下结论正确的是

(A) $\hat{b}>b',\hat{a}>a'$　　(B) $\hat{b}>b',\hat{a}<a'$　　(C) $\hat{b}<b',\hat{a}>a'$　　(D) $\hat{b}<b',\hat{a}<a'$

11. **【2012 课标全国文 3 改编】**在一组样本数据 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$ $(n\geqslant 2,x_1,x_2,\cdots,x_n$ 不全相等) 的散点图中，若所有样本点 (x_i,y_i) $(i=1,2,\cdots,n)$ 都在直线 $y=-\dfrac{1}{2}x+1$ 上，这组样本数据的样本相关系数是 (△)，如果该直线就是这些数据的回归直线，那么该模型的决定系数是 (△).

12. 某公司在 x 年的销售额 y（万元）如下表，根据表中数据用最小二乘法得到的回归方程为 $\hat{y}=2x+35$.

x	2016	2017	2018	2019	2020	2021
y	y_1	y_2	y_3	y_4	y_5	y_6

当关于 a,b 的表达式 $\displaystyle\sum_{k=1}^{6}(y_k-bk-a)^2$ 取最小值时，求 $a+b$ 的值.

13. **【人教 A 版选修三习题 8.1.4】**某地区的环境条件适合天鹅栖息繁衍。有人发现了一个有趣的现象，该地区有 5 个村庄，其中 3 个村庄附近栖息的天鹅多，婴儿出生率也较高；2 个村庄附近栖息的天鹅少，婴儿出生率也较低。有人认为婴儿出生率与天鹅数存在相关关系，并得出结论：天鹅能够带来孩子。你同意这个结论吗？为什么？

14. 解答下述问题

(1) 证明：回归直线一定经过点 $\left(\overline{x},\overline{y}\right)$，其中 $\overline{x},\overline{y}$ 分别为 $\{x_i\}_{i=1}^n$ 和 $\{y_i\}_{i=1}^n$ 的算术平均数.

(2) 设成对数据 $(x_1,y_1),\cdots,(x_n,y_n)$ 的一元线性回归方程是 $\hat{y}=\hat{b}x+\hat{a}\left(\hat{b}\neq 0\right)$，且 $\overline{x},\overline{y}$ 分别为 $\{x_i\}_{i=1}^n$ 和 $\{y_i\}_{i=1}^n$ 的算术平均数. 判断下列结论是否正确，并说明理由：

i. 成对数据 $(y_1,x_1),\cdots,(y_n,x_n)$ 的回归直线一定经过点 $\left(\overline{y},\overline{x}\right)$.

ii. 成对数据 $(y_1,x_1),\cdots,(y_n,x_n)$ 的一元线性回归方程是 $\hat{x}=\dfrac{y}{\hat{b}}-\dfrac{\hat{a}}{\hat{b}}$.

15. **【2022 全国乙卷理 19 节选】**为估计一林区某种树木的总材积量，随机选取了 10 棵这种树木，测量每棵树的根部横截面积（单位：m^2）和材积量（单位：m^3），得到如下数据：

样本号 i	1	2	3	4	5	6	7	8	9	10
根部横截面积 x_i	0.04	0.06	0.04	0.08	0.08	0.05	0.05	0.07	0.07	0.06
材积量 y_i	0.25	0.40	0.22	0.54	0.51	0.34	0.36	0.46	0.42	0.40

并计算得 $\sum\limits_{i=1}^{10}x_i^2=0.038$, $\sum\limits_{i=1}^{10}y_i^2=1.6158$, $\sum\limits_{i=1}^{10}x_iy_i=0.2474$.

求该林区这种树木的根部横截面积与材积量的样本相关系数（精确到 0.01）；

参考数据：$\sqrt{1.896}\approx 1.377$

16. **【2016 全国 III 卷文 18 理 18】**下图是我国 2008 年至 2014 年生活垃圾无害化处理量 y（单位：亿吨）的折线图. 图中横轴为年份代码 t，纵轴为年生活垃圾无害化处理量 y，纵轴刻度为 0.80、1.00、1.20、1.40、1.60、1.80.

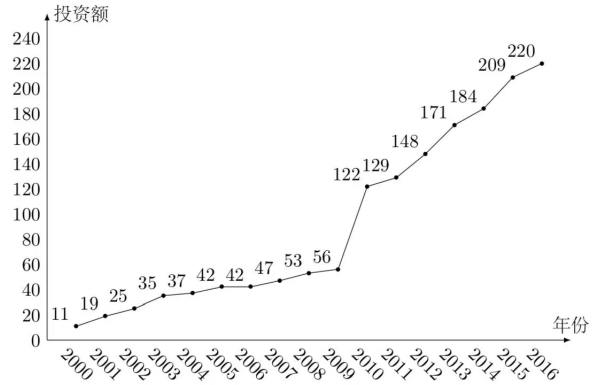
注：年份代码 1-7 分别对应年份 2008-2014.

(1) 由折线图看出，可用线性回归模型拟合 y 与 t 的关系，请用相关系数加以说明；

(2) 建立 y 关于 t 的回归方程（系数精确到 0.01），预测 2016 年我国生活垃圾无害化处理量.

参考数据：$\sum\limits_{i=1}^{7}y_i=9.32$，$\sum\limits_{i=1}^{7}t_iy_i=40.17$，$\sqrt{\sum\limits_{i=1}^{7}\left(y_i-\overline{y}\right)^2}=0.55$，$\sqrt{7}\approx 2.646$.

17. **【2018 全国 II 卷理 18】**下图是某地区 2000 年至 2016 年环境基础设施投资额 y（单位：亿元）的折线图. 为了预测该地区 2018 年的环境基础设施投资额，建立了 y 与时间变量 t 的两个线性回归模型. 根据 2000 年至 2016 年的数据（时间变量 t 的值依次为 $1,2,\cdots,17$）建立模型 (a)：$\hat{y}=-30.4+13.5t$；根据 2010 年至 2016 年的数据（时间变量 t 的值依次为 $1,2,\cdots,7$）建立模型 (b)：$\hat{y}=99+17.5t$. 你认为用哪个模型得到的预测值更可靠？并说明理由.



第 17 题图

18^{U}.【2023“fiddie”模拟考 21】某校 20 名学生的数学成绩 $x_i\,(i=1,2,\ldots,20)$ 和知识竞赛成绩 $y_i\,(i=1,2,\ldots,20)$ 如下表：

学生编号 i	1	2	3	4	5	6	7	8	9	10
数学成绩 x_i	100	99	96	93	90	88	85	83	80	77
知识竞赛成绩 y_i	290	160	220	200	65	70	90	100	60	270
学生编号 i	11	12	13	14	15	16	17	18	19	20
数学成绩 x_i	75	74	72	70	68	66	60	50	39	35
知识竞赛成绩 y_i	45	35	40	50	25	30	20	15	10	5

计算可得数学成绩的平均值是 $\overline{x}=75$，知识竞赛成绩的平均值是 $\overline{y}=90$，并且 $\displaystyle\sum_{i=1}^{20}(x_i-\overline{x})^2=6464,\sum_{i=1}^{20}(y_i-\overline{y})^2=149450,\sum_{i=1}^{20}(x_i-\overline{x})(y_i-\overline{y})=21650.$

(1) 求这组学生的数学成绩和知识竞赛成绩的样本相关系数（精确到 0.01）；

(2) 设 N 是正整数，变量 x 和变量 y 的一组样本数据为 $\{(x_i,y_i)\mid i=1,2,\ldots,N\}$，其中 x_i 两两不同，y_i 两两不同. 记 x_i 在 $\{x_n\mid n=1,2,\ldots,N\}$ 中的排名是第 R_i 位，y_i 在 $\{y_n\mid n=1,2,\ldots,N\}$ 中的排名是第 S_i 位，$i=1,2,\ldots,N$. 定义变量 x 和变量 y 的“斯皮尔曼相关系数”（记为 ρ）为变量 x 的排名和变量 y 的排名的样本相关系数.

i. 记 $d_i=R_i-S_i,i=1,2,\ldots,N$. 证明：$\rho=1-\dfrac{6}{N\left(N^2-1\right)}\displaystyle\sum_{i=1}^{N}d_i^2$；

ii. 用（i）的公式求这组学生的数学成绩和知识竞赛成绩的“斯皮尔曼相关系数”（精确到 0.01）；

(3) 比较（1）和（2.ii）的计算结果，简述“斯皮尔曼相关系数”在分析线性相关性时的优势.

参考数据：$\sqrt{6464\times149450}\approx31000$.

1. **D.**
2. **D.**
3. **A.**
4. **C.**
5. **D.**
6. **D.**
7. **C.**
8. **C.**
9. **D.** x 和 y 的相关系数不是直线 l 的斜率.l 的斜率的取值范围是 $(-\infty,+\infty)$，但是相关系数的取值范围是 $(-1,1)$，故 A 选项错误.

   根据回归直线，相关系数在 -1 到 0 之间，故 B 选项错误.

   当 n 为偶数时，分布在 l 两侧的样本点个数不一定相同，比如极端情况下有可能有离群值. 故 C 选项错误.

   D 选项正确.
10. **C.** 在坐标系上画出散点，可发现直线 $y=b'x+a'$ 的斜率比 $\hat{y}=\hat{b}x+\hat{a}$ 的斜率大，所以 $\hat{b}<b'$. 点 $(0,\hat{a})$ 位于 $\left(0,a'\right)$ 的上方，所以 $\hat{a}>a'$. 故选 C.
11. **-1, 1.** 所有样本点 (x_i,y_i) 都在直线 $y=-\dfrac{1}{2}x+1$ 上，说明 x 与 y 完全负线性相关，即 $|r|=1$ 且 $r<0$，所以样本相关系数为 -1。

    如果该直线就是这些数据的回归直线，那么残差平方和为 0，计算得到该模型的决定系数为 1.
12. **4067.** 设第 k 个数据对应的年份为 $x_k=2015+k,k=1,2,\cdots,6$. 对于原回归方程，将 $x=2015+k$ 代入，得 $\hat{y}=2k+4065$.

    题目中的表达式 $\sum\limits_{k=1}^{6}(y_k-bk-a)^2$ 表示用 $bk+a$ 拟合 y_k 的效果最好，此时应有 $b=2,\quad a=4065$. 所以 $a+b=4065+2=4067$.

    评：一元线性回归分析中，最小二乘法求解 $\hat{a},\hat{b}$ 的公式是怎么来的？学生有必要充分了解这类基本概念。
13. 不同意这个结论.

    这五个村庄的数据只能说明：天鹅数量与婴儿出生率之间存在一定的正相关关系，即天鹅较多的村庄，婴儿出生率往往较高. 但相关关系不等于因果关系，不能据此说明“天鹅能够带来孩子”.

    可能存在第三个共同因素。例如，水源充足、食物丰富、环境宜居的村庄，既适合天鹅栖息，也更适合人类生活，从而可能导致婴儿出生率较高. 真正起作用的可能是环境条件，而不是天鹅本身.

    此外，样本只有 5 个村庄，数量太少，也可能只是偶然现象.

14. (1) 由最小二乘法的推导可知 $\hat{a}=\overline{y}-\hat{b}\overline{x}$.

把它代入回归直线方程 $\hat{y}=\hat{b}x+\hat{a}$，得

$$\hat{y}=\hat{b}x+\overline{y}-\hat{b}\overline{x}=\overline{y}+\hat{b}\left(x-\overline{x}\right)$$

即 $\hat{y}-\overline{y}=\hat{b}\left(x-\overline{x}\right)$.

当 $x=\overline{x}$ 时，$\hat{y}=\overline{y}$，所以说回归直线一定经过点 $\left(\overline{x},\overline{y}\right)$.

从几何上看，这是因为在求 $\hat{a}$ 时，为使 $n\left(\overline{y}-b\overline{x}-a\right)^2$ 取得最小值 0，须取 $a=\overline{y}-b\overline{x}$，即回归直线在 $x=\overline{x}$ 处的纵坐标恰好是样本均值 $\overline{y}$，也就是回归直线必过样本中心 $\left(\overline{x},\overline{y}\right)$.

(2) i. 正确；

ii. 错误。交换变量后，x 对 y 的回归直线一般不是原回归直线的反函数.

设原回归方程为 $\hat{y}=\hat{b}x+\hat{a}$，若相关系数为 r，则可以证明交换变量后的回归方程为

$$\hat{x}=\frac{r^2}{\hat{b}}y+\overline{x}-\frac{r^2}{\hat{b}}\overline{y}$$

仅当 $|r|=1$，即所有点完全共线时，才有 $\hat{x}=\dfrac{y}{\hat{b}}-\dfrac{\hat{a}}{\hat{b}}$，一般情况下不成立.

15. 由题设得

$$\sum_{i=1}^{10}\left(x_i-\overline{x}\right)^2=\sum_{i=1}^{10}x_i^2-10\overline{x}^{,2}=0.038-10\times0.06^2=0.002$$

$$\sum_{i=1}^{10}\left(y_i-\overline{y}\right)^2=\sum_{i=1}^{10}y_i^2-10\overline{y}^{,2}=1.6158-10\times0.39^2=0.0948$$

$$\sum_{i=1}^{10}\left(x_i-\overline{x}\right)\left(y_i-\overline{y}\right)=\sum_{i=1}^{10}x_iy_i-10\overline{x}\,\overline{y}=0.2474-10\times0.06\times0.39=0.0134$$

因此这种树木的根部横截面积与材积量的样本相关系数

$$r=\frac{\displaystyle\sum_{i=1}^{10}\left(x_i-\overline{x}\right)\left(y_i-\overline{y}\right)}{\sqrt{\displaystyle\sum_{i=1}^{10}\left(x_i-\overline{x}\right)^2\sum_{i=1}^{10}\left(y_i-\overline{y}\right)^2}}=\sqrt{\frac{0.0134^2}{0.002\times0.0948}}=\frac{1.34}{\sqrt{1.896}}\approx0.97$$

16. (1) 由折线图中数据和附注中参考数据得

$$\overline{t}=4,\qquad\sum_{i=1}^{7}\left(t_i-\overline{t}\right)^2=28,\qquad\sqrt{\sum_{i=1}^{7}\left(y_i-\overline{y}\right)^2}=0.55$$

$$\sum_{i=1}^{7}\left(t_i-\overline{t}\right)\left(y_i-\overline{y}\right)=\sum_{i=1}^{7}t_iy_i-\overline{t}\sum_{i=1}^{7}y_i=40.17-4\times9.32=2.89$$

$$r\approx\frac{2.89}{0.55\times2\times2.646}\approx0.99$$

因为 y 与 t 的相关系数近似为 0.99，说明 y 与 t 的线性相关程度相当高，从而可以用线性回归模型拟合 y 与 t 的关系.

（2）由 $\overline{y}=\dfrac{9.32}{7}\approx 1.331$ 及（1）可得

$$\hat{b}=\frac{\sum\limits_{i=1}^{7}\left(t_i-\overline{t}\right)\left(y_i-\overline{y}\right)}{\sum\limits_{i=1}^{7}\left(t_i-\overline{t}\right)^2}=\frac{2.89}{28}\approx 0.103$$

$$\hat{a}=\overline{y}-\hat{b}\overline{t}\approx 1.331-0.103\times 4\approx 0.92$$

所以，y 关于 t 的回归方程为 $\hat{y}=0.92+0.10t$.

将 2016 年对应的 $t=9$ 代入回归方程得 $\hat{y}=0.92+0.10\times 9=1.82$，所以预测 2016 年我国生活垃圾无害化处理量将约为 1.82 亿吨.

17. 利用模型 (b) 得到的预测值更可靠。理由如下：

(1) 从折线图可以看出，2000 年至 2016 年的数据对应的点没有随机散布在直线 $y=-30.4+13.5t$ 上下。这说明利用 2000 年至 2016 年的数据建立的线性模型 (a) 不能很好地描述环境基础设施投资额的变化趋势。

2010 年相对 2009 年的环境基础设施投资额有明显增加，2010 年至 2016 年的数据对应的点位于一条直线的附近，这说明从 2010 年开始环境基础设施投资额的变化规律呈线性增长趋势，利用 2010 年至 2016 年的数据建立的线性模型 $y=99+17.5t$ 可以较好地描述 2010 年以后的环境基础设施投资额的变化趋势，因此利用模型　得到的预测值更可靠。

(2) 从计算结果看，相对于 2016 年的环境基础设施投资额 220 亿元，由模型 (a) 得到的预测值 226.1 亿元的增幅明显偏低，而利用模型 (b) 得到的预测值的增幅比较合理，说明利用模型 (b) 得到的预测值更可靠。

18. （1）0.70

(2.i) 由题可知，

$$\sum_{i=1}^{N}R_i=\sum_{i=1}^{N}S_i=\frac{N(N+1)}{2},\sum_{i=1}^{N}R_i^2=\sum_{i=1}^{N}S_i^2=\frac{N(N+1)(2N+1)}{6}.$$

从而变量 x 和变量 y 的平均数 $\overline{R},\overline{S}$ 满足 $\overline{R}=\overline{S}=\dfrac{N+1}{2}$. 因此

$$\begin{aligned}\sum_{i=1}^{N}\left(R_i-\overline{R}\right)^2&=\sum_{i=1}^{N}R_i^2-2\overline{R}\sum_{i=1}^{N}R_i+N\overline{R}^2\\&=\sum_{i=1}^{N}R_i^2-N\overline{R}^2\\&=\frac{N(N+1)(2N+1)}{6}-\frac{N(N+1)^2}{4}\\&=\frac{N(N+1)(N-1)}{12}.\end{aligned}$$

同理可得

$$\sum_{i=1}^{N}\left(S_i-\overline{S}\right)^2=\frac{N(N+1)(N-1)}{12}.$$

由于

$$\sum_{i=1}^{N} d_i^2 = \sum_{i=1}^{N} (R_i - S_i)^2 = \sum_{i=1}^{N} \left[\left(R_i - \overline{R}\right) - \left(S_i - \overline{S}\right) \right]^2$$

所以

$$\begin{aligned} \sum_{i=1}^{N} d_i^2 &= \sum_{i=1}^{N} \left(R_i - \overline{R}\right)^2 + \sum_{i=1}^{N} \left(S_i - \overline{S}\right)^2 - 2\sum_{i=1}^{N} \left(R_i - \overline{R}\right)\left(S_i - \overline{S}\right) \\ &= \frac{N(N+1)(N-1)}{6} - 2\sum_{i=1}^{N} \left(R_i - \overline{R}\right)\left(S_i - \overline{S}\right). \end{aligned}$$

所以

$$\begin{aligned} \rho &= \frac{\sum_{i=1}^{N} \left(R_i - \overline{R}\right)\left(S_i - \overline{S}\right)}{\sqrt{\sum_{i=1}^{N} \left(R_i - \overline{R}\right)^2} \sqrt{\sum_{i=1}^{N} \left(S_i - \overline{S}\right)^2}} = \frac{\frac{N(N+1)(N-1)}{12} - \frac{1}{2}\sum_{i=1}^{N} d_i^2}{\frac{N(N+1)(N-1)}{12}} \\ &= 1 - \frac{6}{N(N^2-1)} \sum_{i=1}^{N} d_i^2. \end{aligned}$$

(2.ii) 答案 1：斯皮尔曼相关系数对于异常值不太敏感，如果数据中有明显的异常值，那么用斯皮尔曼相关系数比用样本相关系数更能刻画某种线性关系。

答案 2：斯皮尔曼相关系数刻画的是样本数据排名的样本相关系数，与具体的数值无关，只与排名有关。如果一组数据有异常值，但排名依然符合一定的线性关系，则可以采用斯皮尔曼相关系数刻画线性关系。